Projet MLOps

Pipeline de Classification 20 Newsgroups de Bout en Bout

March 11, 2026

Problème & Approche

Objectif

Construire un système ML prêt pour la production qui :

- Classe du texte dans **20 catégories**
- Se réentraîne chaque semaine automatiquement
- Trace chaque expérience pour la reproductibilité
- Sert les prédictions via une interface web

Jeu de données — 20 Newsgroups

$\sim$18 000 entraînement / $\sim$7 500 test

20 classes : politique, sport, science, tech...

Étapes du pipeline

1. **Téléchargement** — via scikit-learn
2. **Prétraitement** — nettoyage du texte
3. **Entraînement** — 6 modèles TF-IDF
4. **Promotion** — champion si meilleur

Modèles entraînés par exécution

Modèle	Variantes
SGDClassifier	α=10^{-4}, 10^{-3}
MultinomialNB	α=0.1, 1.0
LogisticRegression	C=1, 10

Architecture

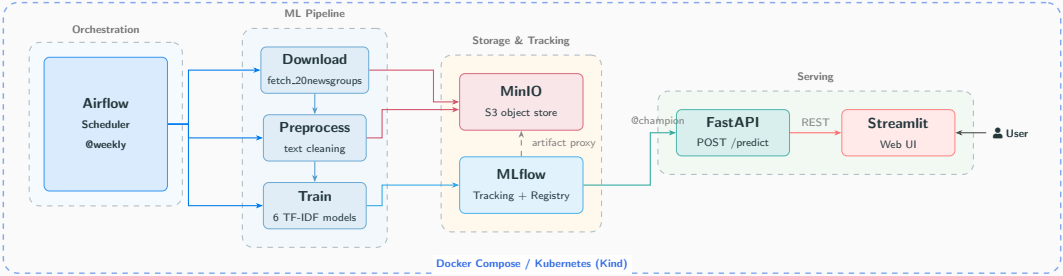

Choix Technologiques

Décisions de conception

- Airflow avec SQLite pour simplifier.
- Proxy d'artefacts via MLflow — clients sans accès S3
- Promotion champion — alias mis à jour si F1 s'améliore

Déploiement en une commande

- `make dev` — stack Docker Compose
- `make k8s-dev` — cluster Kind
- Même image pipeline, opérateur interchangeable

Résultats & Démo

Comparaison des modèles

Modèle	Acc.	F1
LogReg C=10	0.82	0.81
LogReg C=1	0.81	0.80
SGD α=10^{-4}	0.80	0.79
NB α=0.1	0.78	0.77
SGD α=10^{-3}	0.77	0.76
NB α=1.0	0.76	0.74

Champion : LogReg C=10

Promu automatiquement par le pipeline.

Toutes les exécutions tracées dans MLflow.

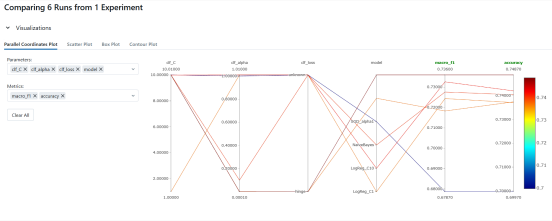

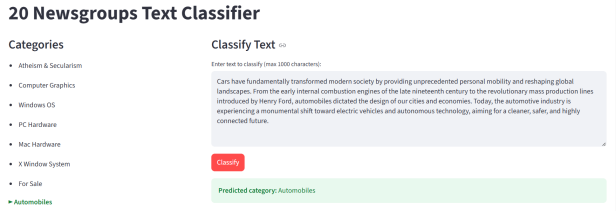

Bilan & Perspectives

Ce que nous avons construit

1. Pipeline automatisé : téléchargement, prétraitement, entraînement
2. 6 modèles comparés par exécution dans MLflow
3. Promotion du champion empêchant les régressions
4. API REST + interface web pour les prédictions
5. Déploiement Docker Compose **ou** K8s (Kind)

Perspectives

- Modèles deep learning (BERT)
- Détection de Data Drift
- CI/CD via GitHub Actions
- PostgreSQL pour Airflow à l'échelle
- Optimisation des modèles en implémentant Grid Search & Cross Validation

Merci — Questions ?